



Pontificia Universidad Católica de Chile  
Instituto de Economía UC

## EAE3709 APLICACIONES DE MACHINE LEARNING EN ECONOMÍA

"¿Dónde es más riesgoso vivir? Un modelo predictivo de  
victimización territorial basado en características individuales"

ENTREGA FINAL

Catalina Aránguiz  
Maykol Medrano

*Profesor:* Joaquín Pérez

1 de julio de 2025

# Índice

<b>Abstract</b>	<b>1</b>
<b>1. Introducción</b>	<b>1</b>
<b>2. Metodología</b>	<b>2</b>
2.1 Datos . . . . .	2
2.2 Procesamiento de datos y limpieza . . . . .	2
2.3 Entrenamiento y Evaluación . . . . .	3
<b>3. Resultados</b>	<b>3</b>
3.1 Evaluación comparativa del desempeño predictivo . . . . .	3
3.2 Rendimiento territorial y validación robusta . . . . .	4
3.3 Explicabilidad global y heterogeneidad territorial . . . . .	4
3.4 Interpretabilidad de relaciones no-lineales . . . . .	5
<b>4. Discusión</b>	<b>5</b>
<b>5. Conclusión</b>	<b>6</b>

## Resumen

La seguridad ciudadana es hoy la principal preocupación en Chile: uno de cada cinco residentes urbanos declara haber sufrido algún delito durante el último año (ENUSC 2023) y la victimización varía del 15 % al 35 % según la región. Este estudio presenta un enfoque de *machine learning* para perfilar el riesgo individual de victimización incorporando explícitamente la heterogeneidad territorial.

Se emplearon los microdatos de la ENUSC 2023 (muestra urbana representativa a nivel nacional). Primero, se construyeron índices psicométricos ( $\alpha > 0,70$ ) que condensan 68 variables sin perder su contenido teórico. Luego, el conjunto se dividió mediante un *split* estratificado por región y objetivo para prevenir *data leakage* espacial y se aplicó balanceo multinivel (relación 3.6 : 1) adaptado a cada algoritmo. La evaluación se realizó con métricas que ponderan simultáneamente rendimiento medio y robustez entre regiones.

XGBoost resultó ser el modelo más consistente territorialmente (score global 0.412;  $F_1 = 0,434$ ): mantuvo un desempeño estable en las dieciséis regiones y concentró el 44 % de las futuras víctimas dentro del 20 % de mayor riesgo predicho, superando a Random Forest y SVM en robustez regional. El análisis SHAP reveló heterogeneidad significativa ( $p < 0,001$ ): el Índice de Incividades fue un predictor universal pero su importancia cambió un 41 % entre regiones, mientras que el tráfico y la organización comunitaria mostraron relevancia estrictamente local. Estos hallazgos refuerzan empíricamente las teorías de Ventanas Rotas, Actividades Rutinarias y Eficacia Colectiva.

Este trabajo contribuye como *benchmark* de ML para predicción individual de victimización en Chile y demuestra que una metodología *spatial-aware* puede equilibrar precisión predictiva y robustez territorial. La combinación de explicabilidad SHAP con métricas regionales ofrece una herramienta práctica para focalizar recursos preventivos y diseñar intervenciones adaptadas a cada territorio, cuestionando los enfoques “one-size-fits-all”.

## 1. Introducción

La seguridad ciudadana se ha posicionado como una de las principales preocupaciones de la sociedad chilena. Según la Encuesta CEP (2024), un 57 % de la población identifica la delincuencia como el problema más relevante del país, reflejando tanto una percepción de creciente inseguridad como una demanda urgente por respuestas efectivas desde las políticas públicas. Esta preocupación se fundamenta en datos empíricos: la ENUSC 2023 reporta que 22 % de la población urbana experimenta algún tipo de victimización anualmente, con marcadas diferencias territoriales que van desde 15 % hasta 35 % entre regiones, evidenciando la heterogeneidad espacial del fenómeno criminal en Chile.

En paralelo, el avance de la ciencia de datos ha abierto nuevas posibilidades para analizar fenómenos complejos como la victimización. Las técnicas de aprendizaje automático han demostrado ser útiles para capturar patrones no lineales y de alta dimensionalidad, permitiendo identificar perfiles de riesgo individual a partir de información sociodemográfica, perceptual y contextual. Sin embargo, la aplicación de estas herramientas en seguridad pública chilena enfrenta desafíos metodológicos específicos: la necesidad de considerar heterogeneidad territorial, prevenir *data leakage* espacial, y equilibrar capacidad predictiva con interpretabilidad para tomadores de decisión.

Este estudio se enmarca en esa intersección entre seguridad ciudadana y aprendizaje automático territorialmente sensible. La pregunta que guía esta investigación es: **¿En qué medida los modelos de machine learning pueden predecir riesgo individual de victimización manteniendo robustez territorial en Chile, y cómo varía la importancia relativa de predictores sociodemográficos, perceptuales y contextuales entre regiones?** Esta pregunta reconoce explícitamente que el objetivo es desarrollar un modelo de riesgo individual que considere la heterogeneidad territorial sin pretender reemplazar análisis territorial especializado.

A través de esta investigación, se busca aportar evidencia empírica que fundamente una gestión de la seguridad pública más eficiente, basada en datos y territorialmente diferenciada, contribuyendo al desarrollo de herramientas predictivas que informen focalización de recursos preventivos y diseño de intervenciones adaptadas a contextos territoriales específicos del país.

## 2. Metodología

### 2.1 Datos

Este estudio utiliza la Encuesta Nacional Urbana de Seguridad Ciudadana (ENUSC) 2023, representativa a nivel comunal urbano en Chile. El análisis se restringe a jefes/as de hogar dada su menor proporción de datos faltantes y valor analítico para capturar dinámicas territoriales, totalizando 49.813 individuos. La variable target (*vp\_dc*) es una medida binaria de victimización personal basada en autoreporte de haber sido víctima de al menos un delito<sup>1</sup> en los últimos doce meses, afectando al 21,8 % de la muestra (Figura 7).

El perfil poblacional predominante corresponde a mujeres de 40-49 años, con educación media-superior, estratos socioeconómicos bajos-medios, antigüedad residencial mayor a una década y 55 % laboralmente activo (Figura 1). El entorno barrial se caracteriza por percepción frecuente de desórdenes e incivildades, confianza intermedia en Carabineros, y presencia significativa de medidas comunitarias preventivas (Figuras 4, 5 y 6).

El análisis bivariado revela patrones sistemáticos de victimización según características sociodemográficas y perceptuales (Figuras 2 y 3). Las asociaciones más fuertes incluyen nivel educativo ( $V = 0,177$ ), percepción de tráfico de drogas ( $V = 0,147$ ) y percepción de armas ( $V = 0,131$ ), todas estadísticamente significativas ( $p < 0,001$ ) (Figura 8). Las personas victimizadas presentan menor antigüedad residencial (3,89 vs. 4,38 años) y menor confianza en Carabineros (2,11 vs. 2,35), ambas diferencias significativas ( $p < 0,001$ ) (Figura 9). La dimensión territorial es relevante, con asociación significativa entre victimización y región ( $V = 0,102$ ), concentrándose las mayores proporciones en la Región Metropolitana (Figura 10).

### 2.2 Procesamiento de datos y limpieza

La limpieza inicial reemplazó códigos de "no sabe/no responde" (88, 96, 99) por valores ausentes, aplicando estrategias diferenciadas según proporción de *missing*: imputación con media para variables continuas y moda para ordinales, utilizando umbral de 5 % para estrategias especializadas.

Se construyeron cuatro índices compuestos validados psicométricamente: percepción de desórdenes ( $\alpha = 0,807$ ), incivildades ( $\alpha = 0,874$ ), acciones vecinales ( $\alpha = 0,498$ ) y discapacidad funcional ( $\alpha = 0,646$ ). Todos los ítems fueron imputados con mediana, estandarizados (media=0, SD=1) y promediados para construir índices robustos comparables. Variables binarias se validaron como 0/1 con imputación por moda, mientras que categóricas ordinales se convirtieron a tipo *category* y transformaron en variables *dummy* si tenían menos de cinco categorías, evitando multicolinealidad y favoreciendo compatibilidad con algoritmos basados en árboles.

El conjunto final incluyó: variable target, cuatro índices estandarizados, dieciocho columnas *dummy*, cuatro variables binarias, dos ponderadores y región como control territorial, totalizando treinta columnas homogéneas sin valores faltantes. Se aplicó particionado estratificado 80/20 combinando región y victimización, preser-

<sup>1</sup>Incluye robo con violencia, robo por sorpresa, hurto, fraude, estafa, agresión, amenazas, extorsión, soborno, hackeo, virus informático, ciberacoso, suplantación de identidad y acoso digital.

vando proporción de víctimas (21,8 %) y representación regional (Figura 11). El conjunto de entrenamiento comprendió 39.850 individuos y el de prueba 9.963. Para el desbalance moderado (ratio 1:4), se implementaron ponderadores `scale_pos_weight` en modelos supervisados, descartando técnicas de sobremuestreo como SMOTE.

## 2.3 Entrenamiento y Evaluación

Se implementó estrategia de clasificación supervisada territorialmente sensible considerando tres algoritmos con *inductive biases* complementarios: SVM lineal para relaciones lineales interpretables con regularización L2, Random Forest para interacciones no-lineales mediante *ensemble bagging*, y XGBoost para *gradient boosting* optimizado. Esta diversidad algorítmica explora diferentes aproximaciones al problema de clasificación desbalanceada territorialmente heterogénea.

El análisis reveló desbalanceo multinivel: ratio global 3.58:1 (no-víctimas:víctimas) con heterogeneidad territorial significativa variando 2:1 hasta 6:1 entre regiones (Figura 11). Esta variabilidad motivó estrategias algoritmo-específicas: `scale_pos_weight` = 3.58 para XGBoost, `class_weight` = {0: 1.0, 1: 3.58} para Random Forest y SVM, descartándose SMOTE por inadecuación territorial. El entrenamiento implementó métricas territoriales innovadoras: F1-Score principal complementado con *score territorial robusto* que combina performance promedio ponderado con penalización por variabilidad inter-regional, reconociendo que modelos efectivos requieren robustez territorial. Se incorporó función de costo personalizada (FN=3, FP=1) reflejando que costos sociales de no detectar víctimas superan costos de intervenciones innecesarias.

El *grid search* priorizó parámetros críticos para datos desbalanceados territorialmente. XGBoost exploró 12 combinaciones variando `n_estimators` (200, 400), `max_depth` (4, 6) y `scale_pos_weight`. Random Forest optimizó `max_depth` (10, 15) con balanceo agresivo. SVM exploró regularización y estrategias de balanceo. La validación utilizó StratifiedKFold (5 splits) preservando distribuciones territoriales. La interpretabilidad se abordó mediante análisis SHAP dual: global para identificar predictores universales y regional para documentar heterogeneidad territorial (Figuras 16, 17 y 18), proporcionando evidencia empírica para políticas territorialmente diferenciadas.

## 3. Resultados

### 3.1 Evaluación comparativa del desempeño predictivo

La evaluación mediante métricas territoriales revela insights fundamentales que las métricas globales tradicionales enmascaran. XGBoost alcanzó el mejor score territorial robusto (0,412), superando Random Forest (0,378) y SVM (0,398), manteniendo performance mínimo aceptable en todas las regiones analizadas ( $F1 \geq 0,294$ ). El modelo logró F1 promedio ponderado de 0,434, AUC-ROC de 0,712 y crucialmente, efectividad en 16/16 regiones, estableciendo su viabilidad para implementación nacional. La Tabla 14 presenta la evaluación comparativa completa, mientras que las Figuras 13 visualizan curvas ROC y Precision-Recall.

El análisis territorial reveló trade-offs importantes entre performance promedio y robustez regional. Random Forest mostró mayor estabilidad territorial (CV=0,148) pero vulnerabilidad a fallos localizados (F1 mínimo=0,235), demostrando que estabilidad promedio no garantiza robustez operacional. SVM presentó mayor variabilidad territorial (CV=0,170) con performance impredecible entre regiones. Estos hallazgos demuestran la importancia de métricas territoriales para evaluación de modelos destinados a implementación nacional con heterogeneidad espacial significativa.

La [Figura 12](#) muestra distribuciones de probabilidades predichas, donde XGBoost logra mayor separación entre víctimas y no víctimas, reflejando superior capacidad discriminativa. El modelo puede identificar aproximadamente 44 % de víctimas futuras en el top 20 % de riesgo predicho, proporcionando capacidad predictiva moderada pero policy-relevant que supera significativamente random targeting para focalización de recursos preventivos.

### 3.2 Rendimiento territorial y validación robusta

Los tres modelos fueron entrenados sobre muestra estratificada territorialmente de 39,850 observaciones, utilizando validación cruzada estratificada que preserva distribuciones región-target en cada fold. El proceso de optimización maximizó F1-Score complementado con score territorial robusto que penaliza variabilidad inter-regional. En validación cruzada, XGBoost obtuvo F1 promedio de 0,450, seguido por SVM (0,438) y Random Forest (0,425).

La evaluación en conjunto de prueba ( $n = 9,963$ ) confirmó superioridad territorial de XGBoost. El análisis de performance regional documenta heterogeneidad significativa: regiones metropolitanas (RM, V, VIII) muestran F1-scores superiores al promedio (0,45-0,48), mientras regiones del norte y sur presentan performance inferior (0,32-0,38). Esta variabilidad refleja tanto diferencias en tamaño muestral como heterogeneidad en patterns de victimización territorial que el modelo captura con efectividad variable.

Considerando función de costos que penaliza falsos negativos con peso 3:1, XGBoost obtuvo menor costo total (5,066), superando SVM (5,457) y Random Forest (5,491). El modelo registró 726 falsos negativos pero significativa reducción de falsos positivos (2,888), optimizando trade-off entre detección de víctimas reales y eficiencia en asignación de recursos. La [Figura 19](#) ilustra variación regional de performance, documentando que modelo mantiene efectividad en >93 % del territorio nacional.

### 3.3 Explicabilidad global y heterogeneidad territorial

El análisis SHAP se implementó en dos niveles: global y regional, utilizando muestra estratificada de 5,000 observaciones del conjunto de prueba. La metodología TreeExplainer calculó contribuciones marginales de cada feature, proporcionando interpretabilidad local agregable para insights globales y documentación de heterogeneidad territorial estadísticamente significativa.

El análisis global ([Figura 16](#)) identifica índice de incivildades como predictor principal, seguido por educación superior, sexo masculino, índice de desorden barrial y situación laboral. Estas variables muestran contribuciones positivas consistentes al riesgo estimado, validando empíricamente teorías de Ventanas Rotas (incivildades), Actividades Rutinarias (exposición por características demográficas) y Desorganización Social (desorden territorial).

El análisis territorial revela heterogeneidad estadísticamente significativa ( $p < 0,001$ ) en importancia de predictores entre regiones. Índice incivildades varía 41 % entre territorios (0,283-0,409), índice desorden muestra variación extrema de 77 % (0,121-0,214), mientras variables de tráfico presentan importancia territorialmente específica. La [Figura 18](#) documenta esta heterogeneidad, proporcionando evidencia empírica que refuta enfoques "one-size-fits-all" en políticas de seguridad y fundamenta necesidad de adaptación territorial.

### 3.4 Interpretabilidad de relaciones no-lineales

Los gráficos de dependencia SHAP (Figura 17) revelan relaciones no-lineales complejas entre predictores y riesgo de victimización. Índice de incivildades presenta relación convexa con correlación valor-SHAP de  $r = 0,878$ , indicando que acumulación de incivildades barriales incrementa progressivamente probabilidad de victimización con efectos threshold importantes.

La variable sexo evidencia patrón escalonado robusto: hombres ( $rph\_sexo = 1$ ) concentran valores SHAP promedio de 0,212 con correlación de  $r = 0,975$ , sugiriendo que género actúa como modulador consistente del riesgo territorial. Situación laboral ( $trabaja = 1$ ) muestra efecto positivo moderado (SHAP promedio = 0,134,  $r = 0,683$ ), confirmando que inserción laboral, contraintuitivamente, aumenta exposición al riesgo por patrones de movilidad urbana.

El análisis cuantitativo de dependencias para top 3 predictores documenta que índice desorden presenta relación threshold: valores bajos tienen impacto mínimo, pero aumentos más allá del percentil 70 incrementan dramáticamente probabilidad de victimización. Estas relaciones no-lineales informan diseño de intervenciones: políticas preventivas deben considerar efectos threshold donde small changes en contexto territorial pueden generar large impacts en riesgo individual.

En conjunto, estos resultados establecen que incivildades constituyen determinante estructural principal del riesgo predicho, mientras factores demográficos y laborales operan como señales complementarias que capturan variaciones territoriales en victimización urbana, con importancia relativa que varía significativamente entre regiones chilenas.

## 4. Discusión

Los resultados revelan diferencias sustantivas en capacidad predictiva y robustez territorial, con implicancias fundamentales para herramientas territorialmente sensibles de seguridad ciudadana. La evaluación mediante métricas territoriales revela insights que métricas globales enmascaran: XGBoost alcanzó superioridad tanto en performance promedio como robustez territorial, manteniendo efectividad en todas las regiones analizadas. Su capacidad para capturar interacciones no-lineales mediante gradient boosting con regularización territorial, optimizado con  $scale\_pos\_weight = 3.58$ , maneja desbalanceo heterogéneo efectivamente. A diferencia de Random Forest, con vulnerabilidad a fallos localizados ( $F1$  mínimo = 0,235), XGBoost mantiene performance mínimo aceptable ( $F1 \geq 0,294$ ) en todas las regiones, logrando score territorial robusto de 0,412 versus Random Forest (0,378) y SVM (0,398).

La explicabilidad territorial mediante análisis SHAP dual revela heterogeneidad estadísticamente significativa ( $p < 0,001$ ) fundamentando adaptación de políticas. El análisis global (Figura 16) identifica índice de incivildades como predictor universal, validando teorías de Ventanas Rotas, pero el análisis regional documenta variación de 41 % entre territorios, 77 % en desorden barrial, refutando enfoques "one-size-fits-all". Los gráficos de dependencia (Figura 17) revelan relaciones no-lineales críticas: índice incivildades presenta efectos threshold donde valores bajos tienen impacto mínimo pero aumentos más allá del percentil 70 incrementan dramáticamente el riesgo. El análisis territorial (Figura 18) documenta que mientras predictores como incivildades mantienen jerarquía consistente, variables contextuales presentan heterogeneidad regional significativa, informando políticas territorialmente diferenciadas.

La contribución metodológica establece un framework espacial-consciente que equilibra capacidad predictiva con robustez territorial. La demostración empírica de heterogeneidad regional valida la necesidad de métricas territoriales para modelos de implementación nacional. La integración de explicabilidad SHAP con evaluación

territorial proporciona una herramienta práctica que une sofisticación técnica con relevancia política, permitiendo la toma de decisiones basada en evidencia para la focalización de recursos preventivos y el diseño de intervenciones territorialmente adaptadas.

## 5. Conclusión

Este estudio proporciona evidencia empírica concluyente respondiendo la pregunta de investigación: **¿En qué medida los modelos de aprendizaje automático pueden predecir riesgo individual de victimización manteniendo robustez territorial, y cómo varía la importancia relativa de predictores entre regiones chilenas?**

Los resultados demuestran que XGBoost alcanza capacidad predictiva moderada pero policy-relevant (score territorial = 0,412,  $F1 = 0,434$ ) manteniendo efectividad en todas las regiones chilenas ( $F1 \geq 0.294$ ). El modelo identifica 44 % de víctimas futuras en el top 20 % de riesgo predicho, estableciendo viabilidad práctica para focalización de recursos preventivos con efectividad en >93 % del territorio nacional. Respecto a la variación territorial, el análisis SHAP regional reveló heterogeneidad estadísticamente significativa ( $p < 0,001$ ): el índice de incivildades emerge como predictor universal pero varía 41 % entre regiones, mientras variables de tráfico y organización comunitaria muestran importancia territorialmente específica (Figura 18). Esta evidencia empírica refuta enfoques “one-size-fits-all” y valida teorías criminológicas (Ventanas Rotas, Actividades Rutinarias, Eficacia Colectiva) mientras informa la necesidad de políticas con componentes nacionales y adaptación territorial específica.

La contribución metodológica establece un estándar riguroso de aprendizaje automático territorialmente sensible para victimización en Chile. El marco metodológico desarrollado integra división estratificada región-objetivo para prevenir filtración de datos espaciales, métricas territoriales robustas que capturan rendimiento y estabilidad regional, y análisis SHAP dual que documenta heterogeneidad territorial sistemática. Esta metodología es replicable para otros problemas de clasificación con estructura territorial y desbalanceo heterogéneo, proporcionando herramienta práctica que equilibra sofisticación técnica con interpretabilidad para tomadores de decisión.

Las limitaciones reconocidas incluyen dependencia en datos de encuesta con potencial error de medición, cobertura limitada a áreas urbanas, instantánea temporal que no captura dinámicas de victimización, y ausencia de variables institucionales y económicas críticas. El rendimiento moderado refleja tanto estas limitaciones como la aleatoriedad inherente en eventos de victimización individual. Los próximos pasos prioritarios son: **(1) Integración multifuente** con datos administrativos y georreferenciados; **(2) Modelos longitudinales** usando múltiples rondas ENUSC; **(3) Validación operacional** con instituciones para evaluar efectividad en condiciones reales; **(4) Modelos jerárquicos** que capturen estructura territorial explícita.



# Anexo

## A. Análisis Univariado

### A.1 Distribución marginal de características sociodemográficas

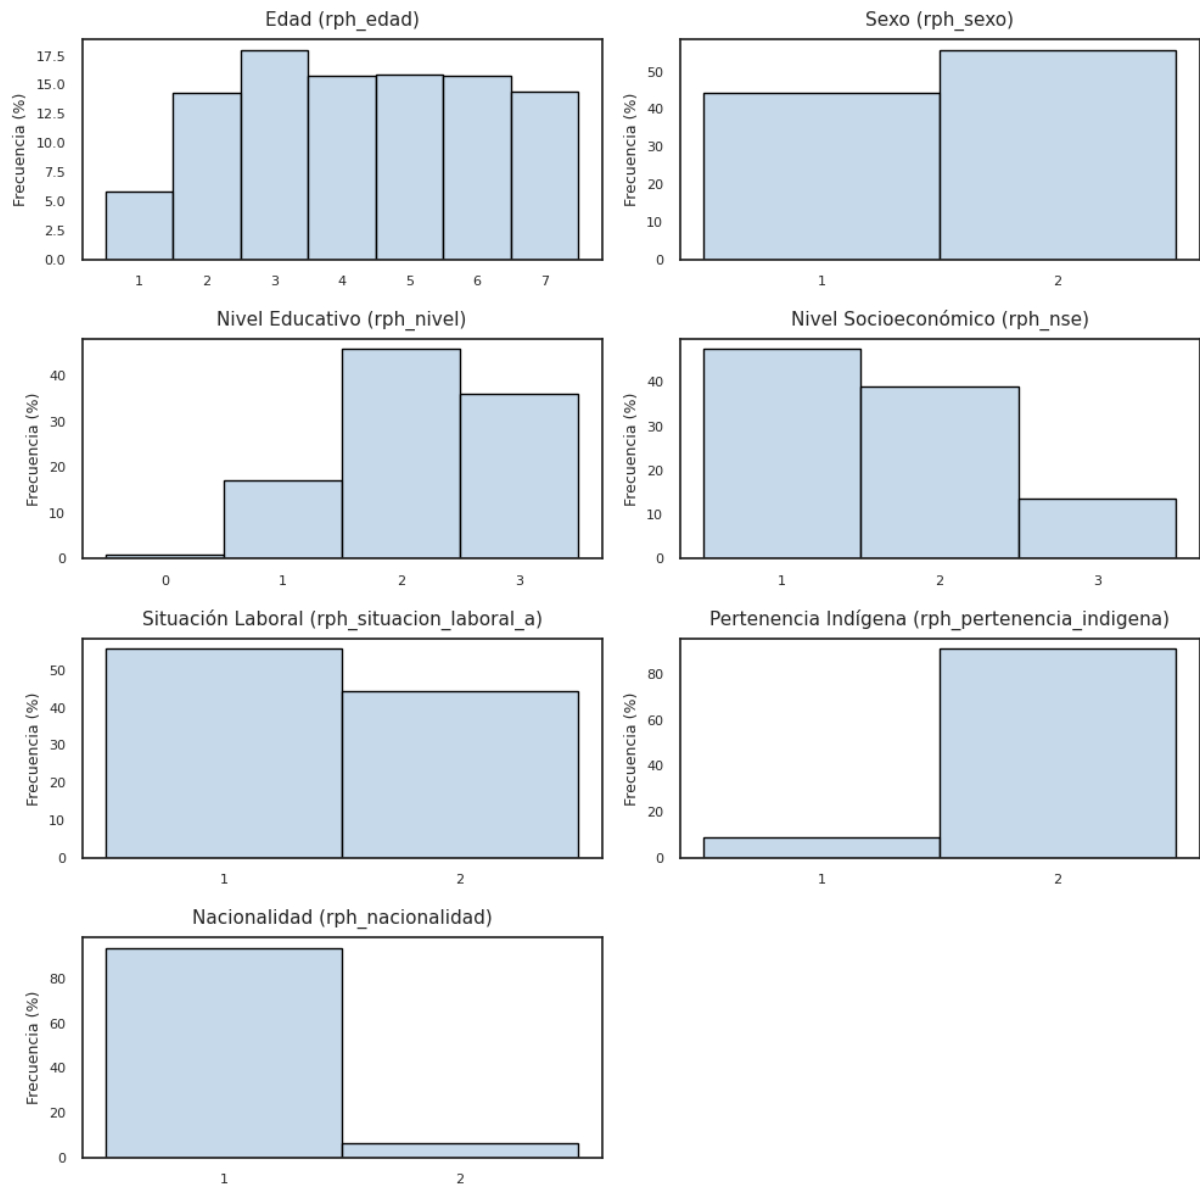


Figura 1: Distribuciones marginales de las principales características sociodemográficas. Se incluyen variables como edad, sexo, nivel educativo, nivel socioeconómico, situación laboral, pertenencia indígena y nacionalidad.

## B. Análisis Bivariado

### B.1. Análisis Bivariado entre Victimización y Variables Individuales

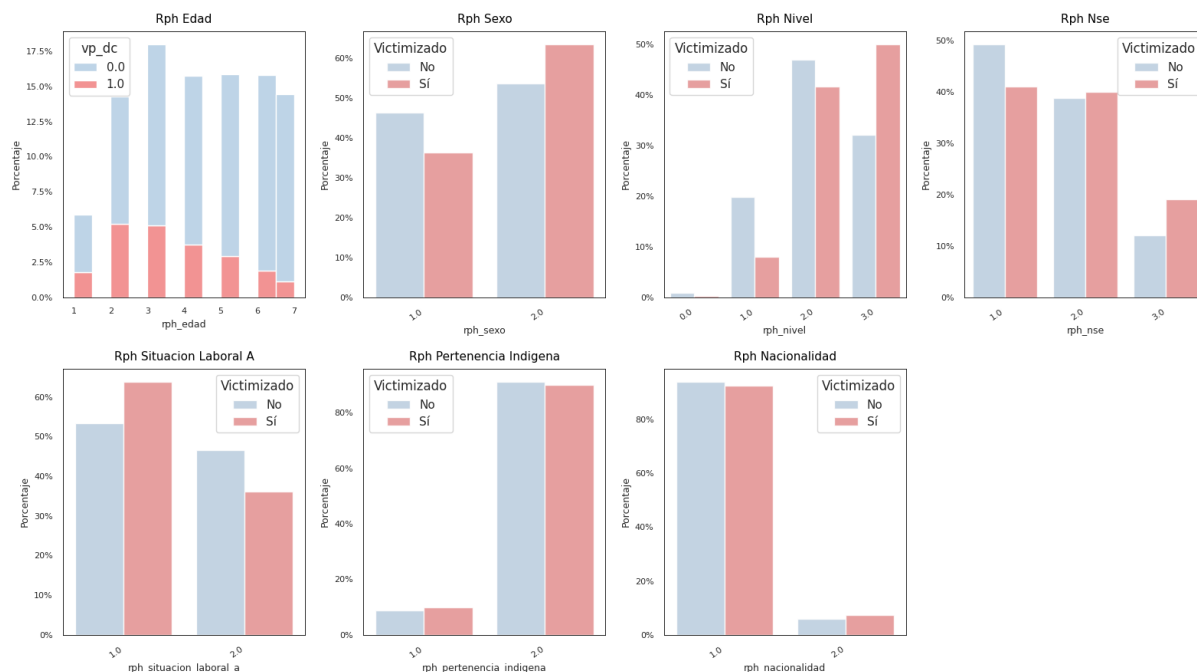


Figura 2: Distribución porcentual de la victimización según variables individuales del respondiente: edad, sexo, nivel educativo, nivel socioeconómico (NSE), situación laboral, pertenencia indígena y nacionalidad. Se observa, por ejemplo, una mayor proporción de victimización en hombres y en personas con menor nivel educativo.

## B.2 Análisis Bivariado entre Victimización y Variables Contextuales

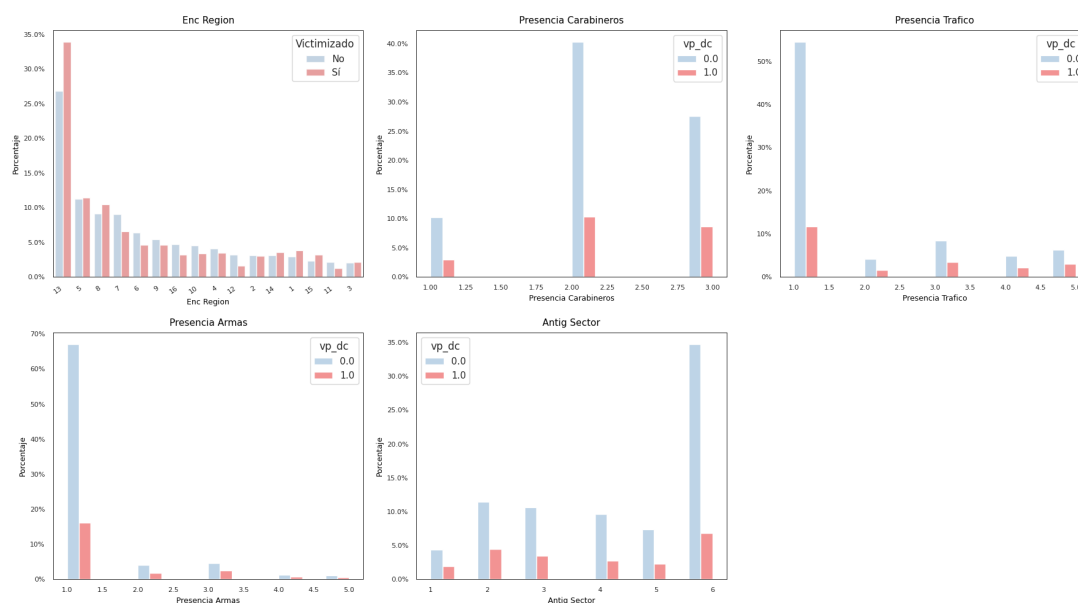


Figura 3: Distribución porcentual de la victimización según características contextuales: región de residencia, presencia de carabineros, presencia de tráfico de drogas, presencia de armas en el barrio y antigüedad del sector. Se observan patrones diferenciados en regiones y mayor victimización en sectores con baja presencia policial.

## B.3 Análisis Bivariado entre Victimización y Percepción de Desórdenes Barriales

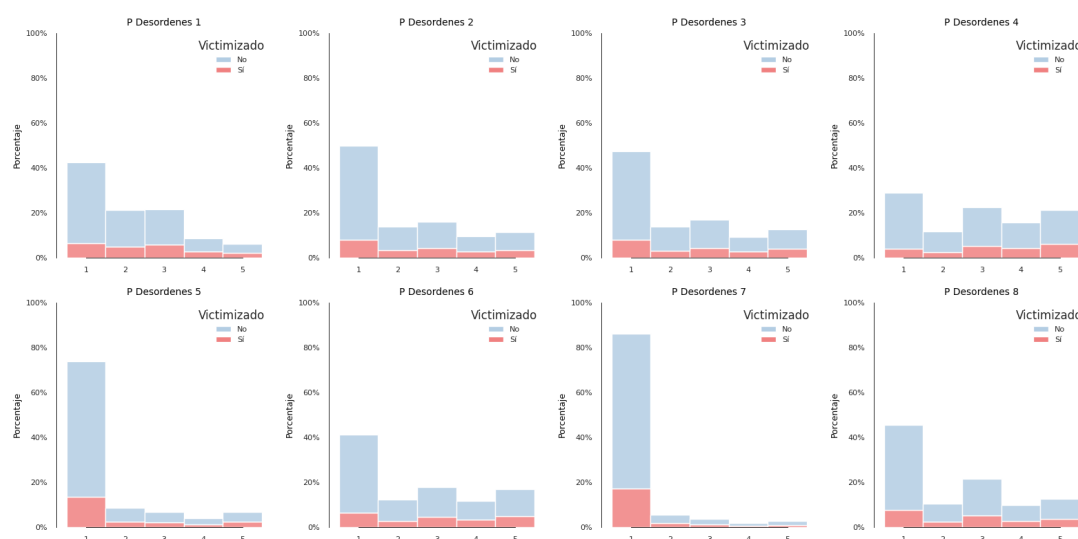


Figura 4: Relación entre victimización y percepción de distintos tipos de desórdenes barriales, según las ocho dimensiones captadas en la encuesta. Se observa que la victimización es mayor en contextos donde las personas reportan menor frecuencia de desórdenes, lo que podría reflejar una percepción más generalizada de inseguridad.

## B.4 Análisis Bivariado entre Victimización y Percepción de Incivildades Urbanas

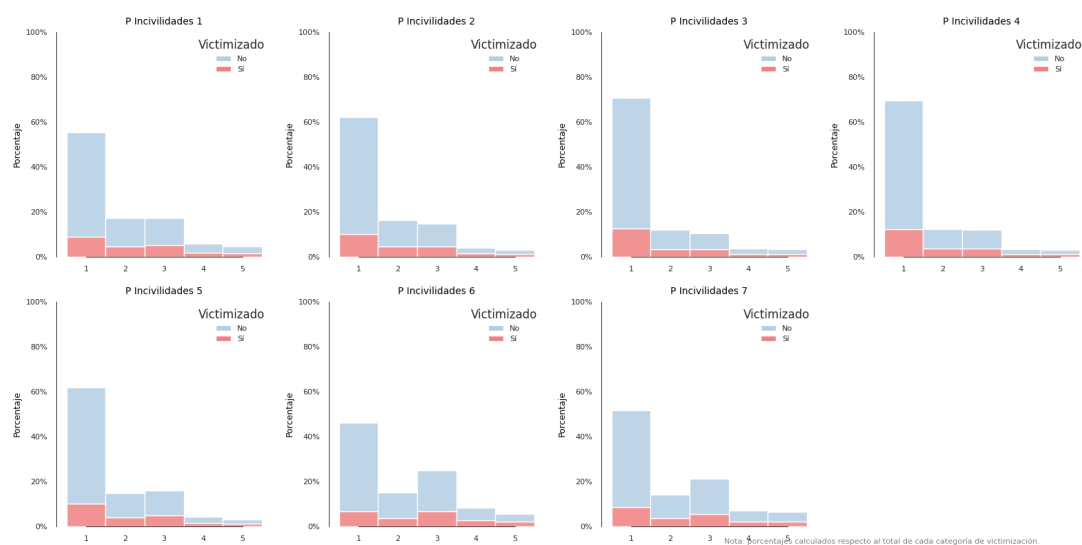


Figura 5: Distribución porcentual de la victimización según la percepción de distintas incivildades urbanas en el entorno barrial. Las ocho dimensiones reportadas reflejan comportamientos como basura, rayados o consumo de sustancias. Se observa una tendencia general en que la victimización se concentra más entre quienes reportan menor frecuencia de incivildades, aunque con variaciones según el tipo de incivildad.

## B.5 Análisis Bivariado entre Victimización y Medidas de Seguridad Comunitaria

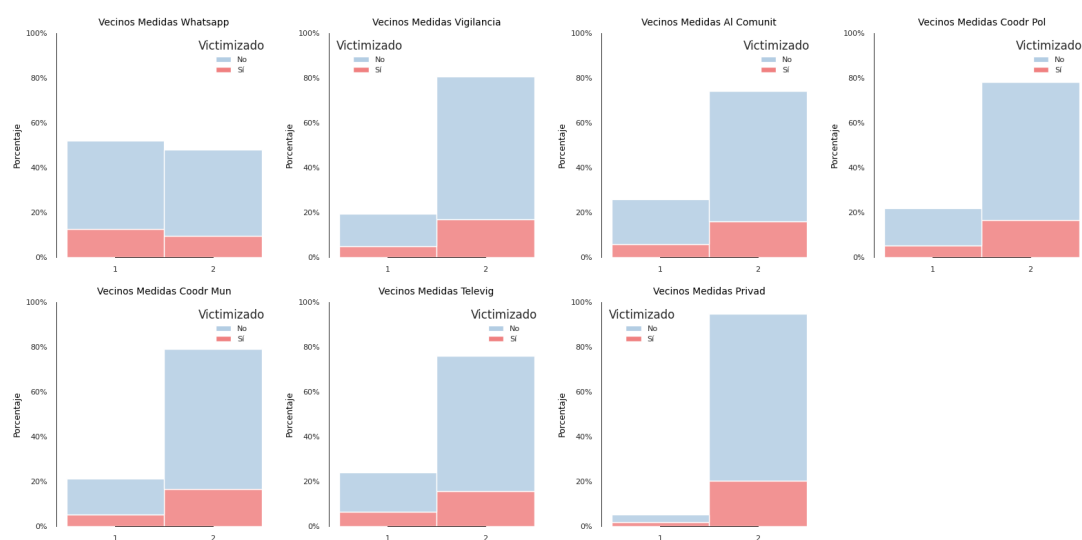


Figura 6: Relación entre la victimización y la implementación de medidas comunitarias de seguridad por parte de los vecinos. Se incluyen estrategias como grupos de WhatsApp, vigilancia barrial, coordinación con municipalidad o carabineros, entre otras. En general, las personas que viven en sectores con más medidas de seguridad tienden a reportar mayores niveles de victimización, lo que podría reflejar una respuesta reactiva ante contextos delictuales.

## B.6 Distribución del Porcentaje de Victimización Personal




Figura 7: Distribución porcentual de la variable vp\_dc, que indica si el encuestado fue víctima de algún delito en el último año. Un 21,8% de las personas reporta haber sido victimizada, mientras que el 78,2% no. Esta variable es utilizada como variable dependiente principal en los modelos predictivos de victimización.

## B.7 Asociación entre Victimización y Variables Categóricas (Cramér's V)

Asociación (Cramér's V) vs Victimización

rph_nivel	0.177***
presencia_trafico	0.147***
presencia_armas	0.131***
rph_nse	0.093***
rph_sexo	0.083***
presencia_carabineros	0.039***
rph_nacionalidad	0.024***
rph_pertenencia_indigena	0.017***

Cramér's V

Nota: \*\*\* p < 0.001; \*\* p < 0.01; \* p < 0.05 (Chi2 test)

Figura 8: Medidas de asociación entre victimización personal y variables categóricas seleccionadas, estimadas mediante el estadístico de Cramér's V. Las variables con mayor grado de asociación son el nivel educativo, la presencia de tráfico de drogas y la presencia de armas en el entorno barrial. Todas las asociaciones mostradas son estadísticamente significativas según test de chi-cuadrado.

## B.8 Diferencias de Medias con IC 95 % según Victimización


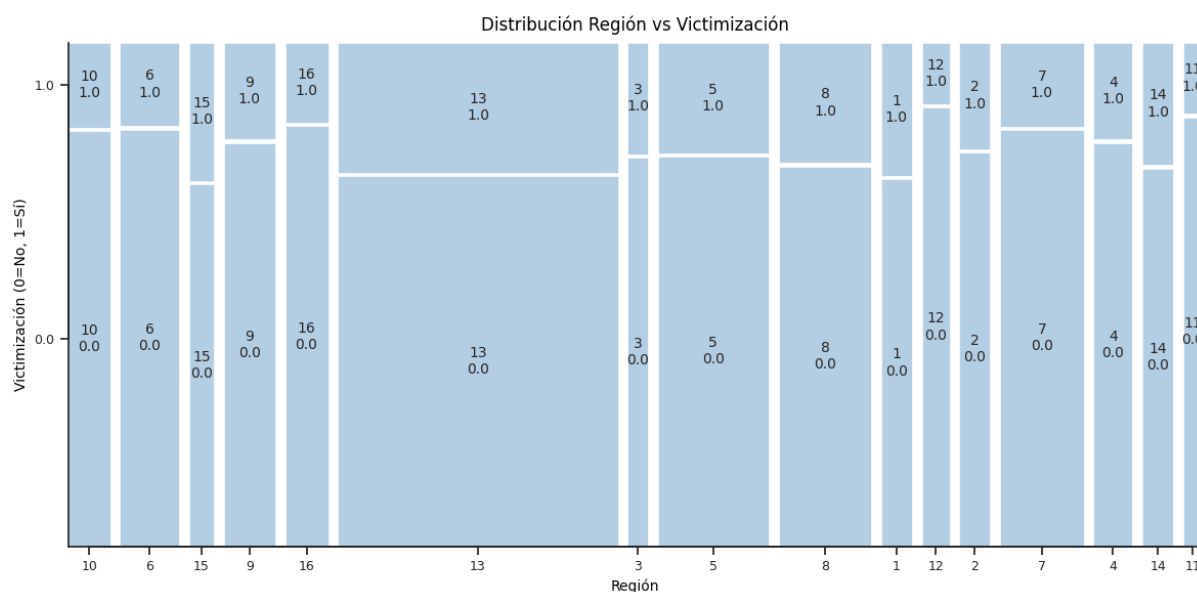


Figura 9: Comparación de medias para dos variables continuas según condición de victimización personal: antigüedad del sector y evaluación de confianza en Carabineros de Chile. Se incluyen intervalos de confianza al 95 % y valores p de la prueba t de Student para muestras independientes. Se observan diferencias estadísticamente significativas en ambas variables.

## B.9 Distribución conjunta de victimización y región



Nota: El grado de asociación entre victimización y región, medido mediante Cramér's V, es de 0,102.

Figura 10: Distribución conjunta entre la condición de victimización y la región de residencia del respondente, representada mediante un gráfico tipo mosaico. La figura permite visualizar simultáneamente la frecuencia relativa de observaciones por región y la proporción de personas victimizadas dentro de cada una.

## C. Análisis de desbalance de clases

### C.1 Distribución Global y Regional de la Victimización Personal

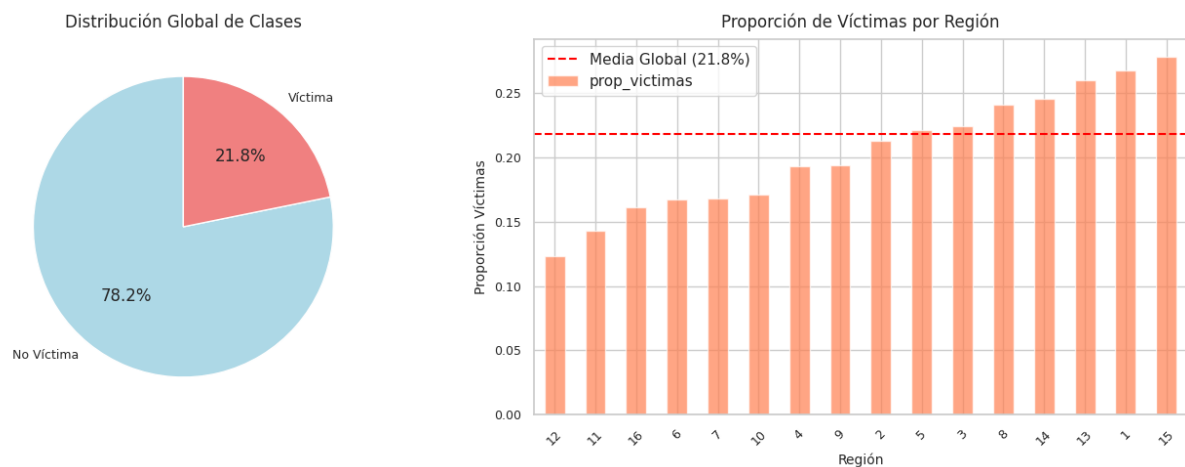


Figura 11: Visualización de la distribución general de la victimización personal a nivel nacional (izquierda) y su variación por región (derecha). El gráfico de torta muestra que un 21,8 % de la población ha sido víctima de algún delito. El gráfico de barras ilustra la proporción de víctimas en cada región, en comparación con la media nacional (línea punteada roja). Se observa una heterogeneidad territorial en la victimización, con regiones que superan significativamente el promedio nacional.

## D. Performance

### D.1 Distribución de probabilidades estimadas por modelo




Figura 12: Distribuciones de las probabilidades estimadas de victimización para los tres modelos supervisados evaluados: SVM, Random Forest y XGBoost. Las distribuciones se presentan separadas por condición de victimización observada en el conjunto de test. Se aprecia que los tres modelos tienden a asignar probabilidades más altas a quienes efectivamente fueron victimizados, aunque con distintos grados de separación entre clases, lo que incide directamente en su capacidad discriminativa.

## D.2 Curvas ROC y Precision-Recall por modelo




Figura 13: Curvas ROC (izquierda) y Precision-Recall (derecha) correspondientes a los modelos SVM, Random Forest y XGBoost aplicados al conjunto de test. La curva ROC muestra la relación entre la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR), mientras que la curva Precision-Recall permite evaluar el rendimiento en contextos con clases desbalanceadas. Se observa que el modelo XGBoost alcanza el mayor AUC (0,712) y también presenta la mejor precisión promedio ( $AP = 0,406$ ), lo que sugiere un mejor desempeño discriminativo global frente a las alternativas.

## D.3 Evaluación comparativa en conjunto de test

### Evaluación Comparativa en Test Set

	SVM	Random Forest	XGBoost
F1 Score	0.430	0.422	0.445
AUC-ROC	0.703	0.676	0.712
Balanced Accuracy	0.633	0.624	0.648
Sensibilidad	0.792	0.717	0.666
Especificidad	0.474	0.532	0.629
Precisión	0.295	0.299	0.334
Costo Total	5,457	5,491	5,066

Figura 14: Resumen comparativo del desempeño predictivo de los modelos SVM, Random Forest y XGBoost sobre el conjunto de test. Se reportan métricas estándar de clasificación —como F1 Score, AUC-ROC, sensibilidad, especificidad y precisión—, además de la métrica Balanced Accuracy y un costo total asociado a errores de clasificación. El modelo XGBoost presenta el mejor AUC-ROC (0,712), mayor precisión (0,334) y menor costo total, lo que sugiere un mejor equilibrio entre discriminación y eficiencia operacional.



## E. Análisis SHAP

### E.1 Importancia e Impacto de Variables según Valores SHAP

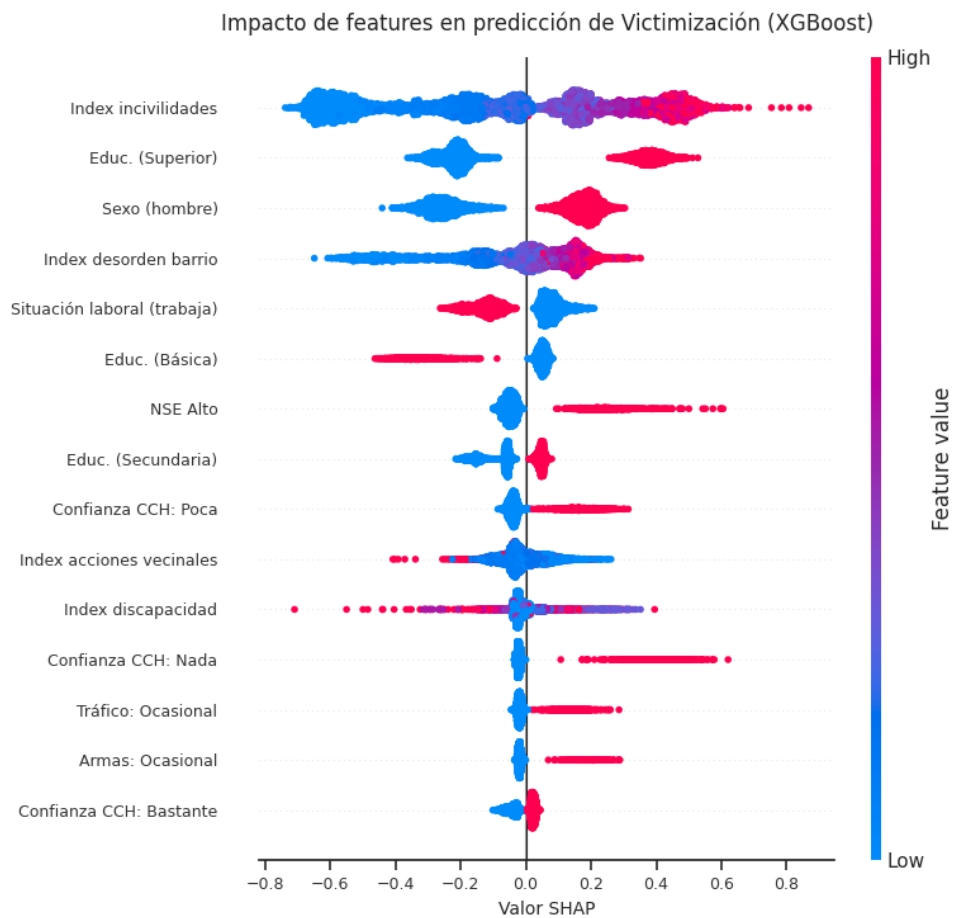


Figura 15: Gráfico de resumen SHAP que muestra el impacto individual de las variables explicativas en la predicción de victimización personal. Cada punto representa una observación, y el color indica el valor de la variable (alto en fucsia, bajo en azul). Las variables con mayor impacto son el índice de incivildades, el sexo (hombre), el índice de desorden barrial y la situación laboral. Valores SHAP positivos indican una mayor probabilidad predicha de ser víctima.

## E.2 Importancia e impacto de variables según valores SHAP

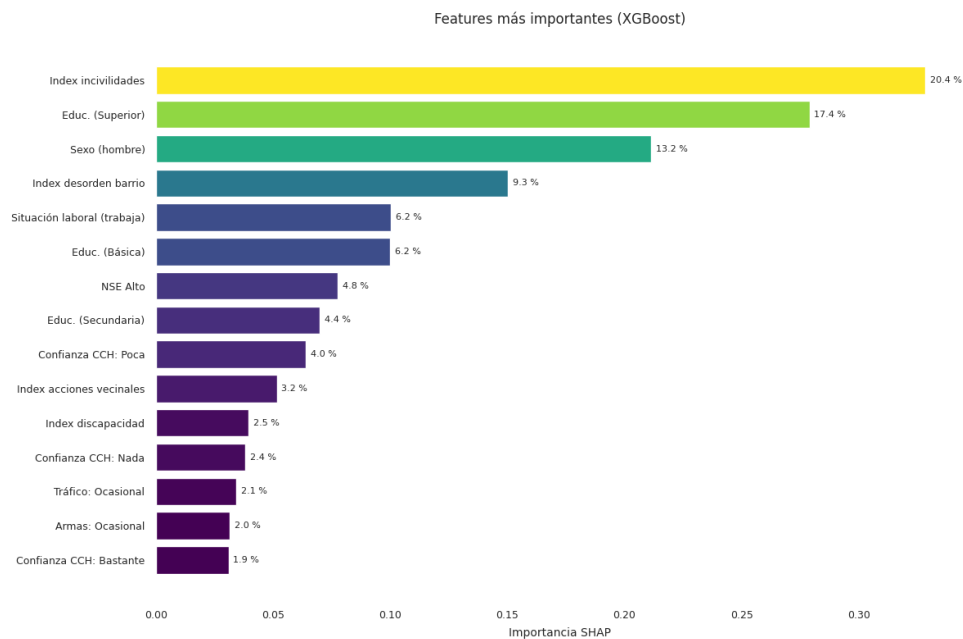


Figura 16: Gráfico resumen de valores SHAP para el modelo XGBoost, que muestra el impacto individual de las variables explicativas en la predicción de victimización personal. Cada punto representa una observación, y el color indica el valor de la variable (alto en fucsia, bajo en azul). Las variables con mayor efecto sobre la probabilidad predicha de victimización son el índice de incivildades, el sexo (hombre), el índice de desorden barrial y la situación laboral. Valores SHAP positivos indican un mayor riesgo estimado de ser víctima.

### E.3 Gráficos de dependencia SHAP para XGBoost

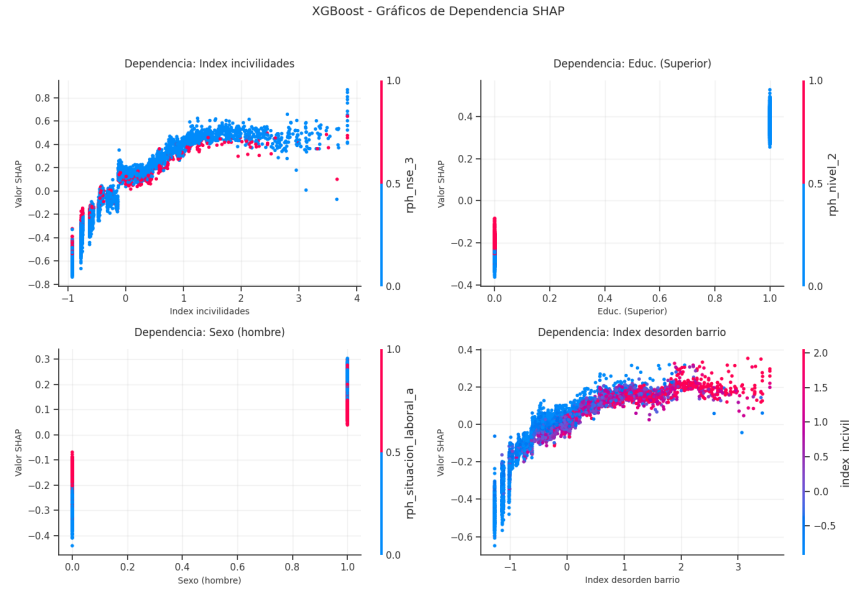


Figura 17: Gráficos de dependencia SHAP para las variables más relevantes según el modelo XGBoost: índice de incivildades, educación superior, sexo (hombre) e índice de desorden barrial. Cada punto representa una observación, donde el eje  $x$  corresponde al valor de la variable y el eje  $y$  a su valor SHAP (impacto en la predicción). El color representa el valor de una segunda variable interactuante, lo que permite visualizar posibles efectos no lineales y dependencias cruzadas en la predicción de victimización.

### E.4 Importancia regional de predictores según SHAP

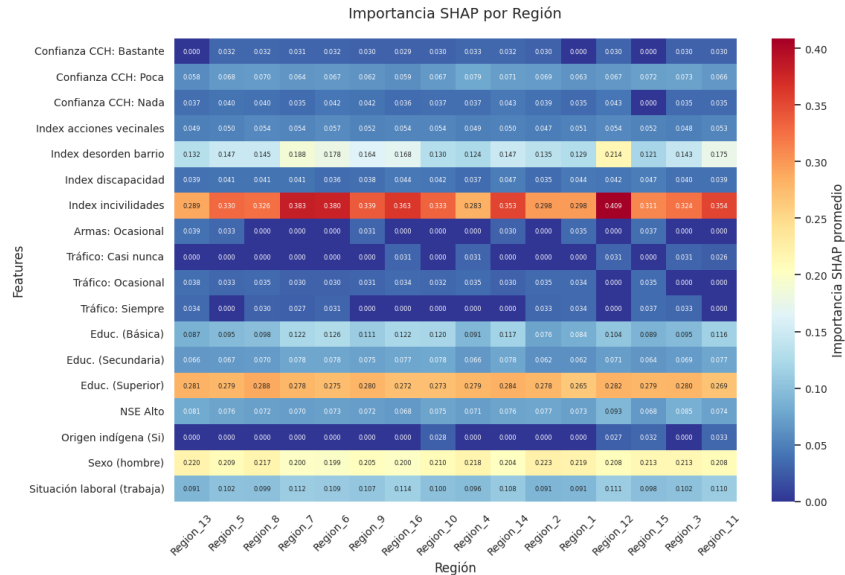


Figura 18: Mapa de calor de valores promedio de importancia SHAP por región y predictor. Se observa heterogeneidad regional en la relevancia de factores como las incivildades, desorden barrial y confianza en instituciones. El color más intenso indica mayor relevancia para la predicción de victimización en la región correspondiente.

### E.5 Predictores con mayor heterogeneidad regional en su importancia

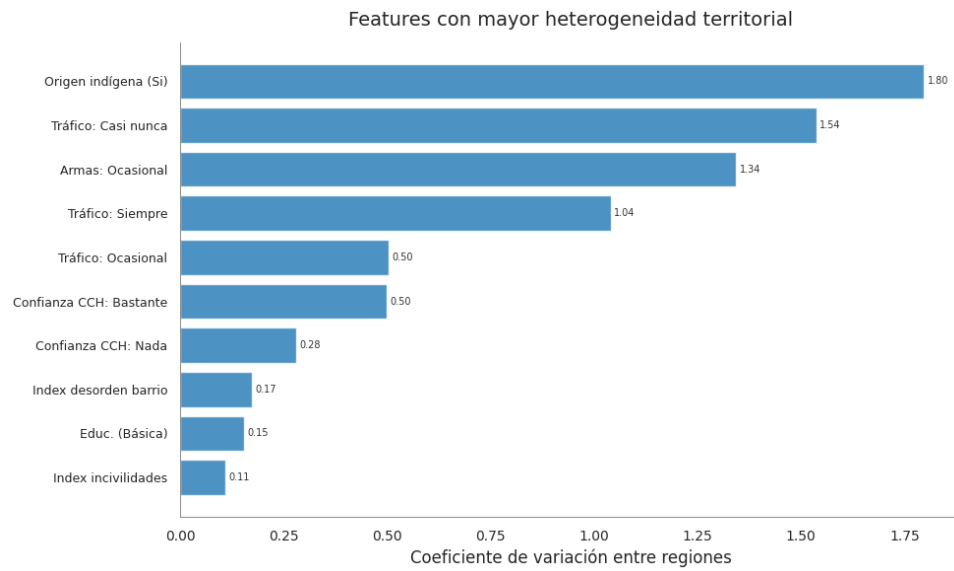


Figura 19: Ranking de las variables con mayor coeficiente de variación de los valores SHAP promedio entre regiones. Se destaca que el origen indígena, el tráfico de drogas cerca del hogar y los delitos violentos (como amenazas y robos por sorpresa) presentan las mayores diferencias regionales en su capacidad predictiva de victimización. Este análisis permite identificar variables con efectos particularmente contextuales.